# 10-浏览器：一个浏览器是如何工作的？（阶段一）

对于前端开发来说，我们平时与浏览器打交道的时间是最多的。可浏览器对前端同学来说更多像一个神秘黑盒子的存在。我们仅仅知道它能做什么，而不知道它是如何做到的。

在我面试和接触过的前端开发者中，70%的前端同学对这部分的知识内容只能达到“一知半解”的程度。甚至还有一部分同学会质疑这部分知识是否重要：这与我们的工作相关吗，学多了会不会偏移前端工作的方向？

事实上，我们这里所需要了解的浏览器工作原理只是它的大致过程，这部分浏览器工作原理不但是前端面试的常考知识点，它还会辅助你的实际工作，学习浏览器的内部工作原理和个中缘由，对于我们做性能优化、排查错误都有很大的好处。

在我们的课程中，我也会控制浏览器相关知识的粒度，把它保持在“给前端工程师了解浏览器”的水准，而不是详细到“给浏览器开发工程师实现浏览器”的水准。

那么，我们今天开始，来共同思考一下。一个浏览器到底是如何工作的。

实际上，对浏览器的实现者来说，他们做的事情，就是把一个URL变成一个屏幕上显示的网页。

这个过程是这样的：

1. 浏览器首先使用HTTP协议或者HTTPS协议，向服务端请求页面；
2. 把请求回来的HTML代码经过解析，构建成DOM树；
3. 计算DOM树上的CSS属性；
4. 最后根据CSS属性对元素逐个进行渲染，得到内存中的位图；
5. 一个可选的步骤是对位图进行合成，这会极大地增加后续绘制的速度；
6. 合成之后，再绘制到界面上。

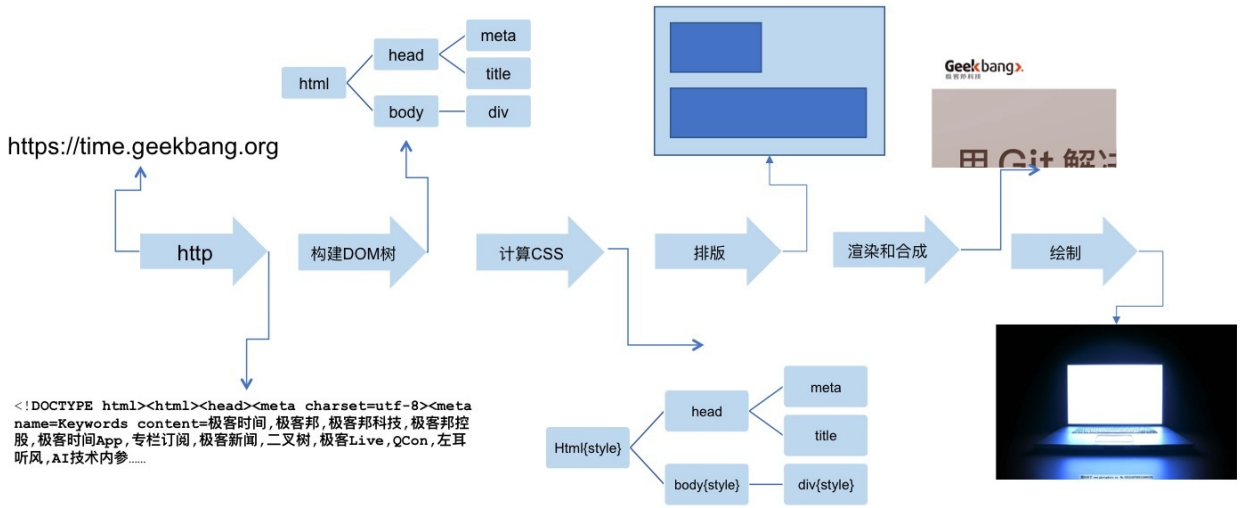


我们在开始详细介绍之前，要建立一个感性认识。我们从HTTP请求回来开始，这个过程并非一般想象中的

一步做完再做下一步，而是一条流水线。

从HTTP请求回来，就产生了流式的数据，后续的DOM树构建、CSS计算、渲染、合成、绘制，都是尽可能地流式处理前一步的产出：即不需要等到上一步骤完全结束，就开始处理上一步的输出，这样我们在浏览网页时，才会看到逐步出现的页面。

首先我们来介绍下网络通讯的部分。

## HTTP协议

浏览器首先要做的事就是根据URL把数据取回来，取回数据使用的是HTTP协议（实际上这个过程之前还有DNS查询，不过这里就不详细展开了。）

我先来了解下HTTP的标准。

HTTP标准由IETF组织制定，跟它相关的标准主要有两份：

1. HTTP1.1 https://tools.ietf.org/html/rfc2616

2.HTTP1.1 https://tools.ietf.org/html/rfc7234

HTTP协议是基于TCP协议出现的，对TCP协议来说，TCP协议是一条双向的通讯通道，HTTP在TCP的基础上，规定了Request-Response的模式。这个模式决定了通讯必定是由浏览器端首先发起的。

大部分情况下，浏览器的实现者只需要用一个TCP库，甚至一个现成的HTTP库就可以搞定浏览器的网络通讯部分。HTTP是纯粹的文本协议，它是规定了使用TCP协议来传输文本格式的一个应用层协议。

下面，我们试着用一个纯粹的TCP客户端来手工实现HTTP一下：

## 实验

我们的实验需要使用telnet客户端，这个客户端是一个纯粹的TCP连接工具（安装方法）。

首先我们运行telnet，连接到极客时间主机，在命令行里输入以下内容：

```
telnet time.geekbang.org 80
```

这个时候，TCP连接已经建立，我们输入以下字符作为请求：

```
GET / HTTP/1.1
Host: time.geekbang.org
```

按下两次回车，我们收到了服务端的回复：

```
HTTP/1.1 301 Moved Permanently
Date: Fri, 25 Jan 2019 13:28:12 GMT
Content-Type: text/html
Content-Length: 182
Connection: keep-alive
Location: https://time.geekbang.org/
Strict-Transport-Security: max-age=15768000

<html>
<head><title>301 Moved Permanently</title></head>
<body bgcolor="white">
<center><h1>301 Moved Permanently</h1></center>
<hr><center>openresty</center>
</body>
</html>
```

这就是一次完整的HTTP请求的过程了，我们可以看到，在TCP通道中传输的，完全是文本。

在请求部分，第一行被称作 request line，它分为三个部分，HTTP Method，也就是请求的“方法”，请求的路径和请求的协议和版本。

在响应部分，第一行被称作 response line，它也分为三个部分，协议和版本、状态码和状态文本。

紧随在request line或者response line之后，是请求头/响应头，这些头由若干行组成，每行是用冒号分隔的名称和值。

在头之后，以一个空行（两个换行符）为分隔，是请求体/响应体，请求体可能包含文件或者表单数据，响应体则是html代码。

### HTTP协议格式

根据上面的分析，我们可以知道HTTP协议，大概可以划分成如下部分。

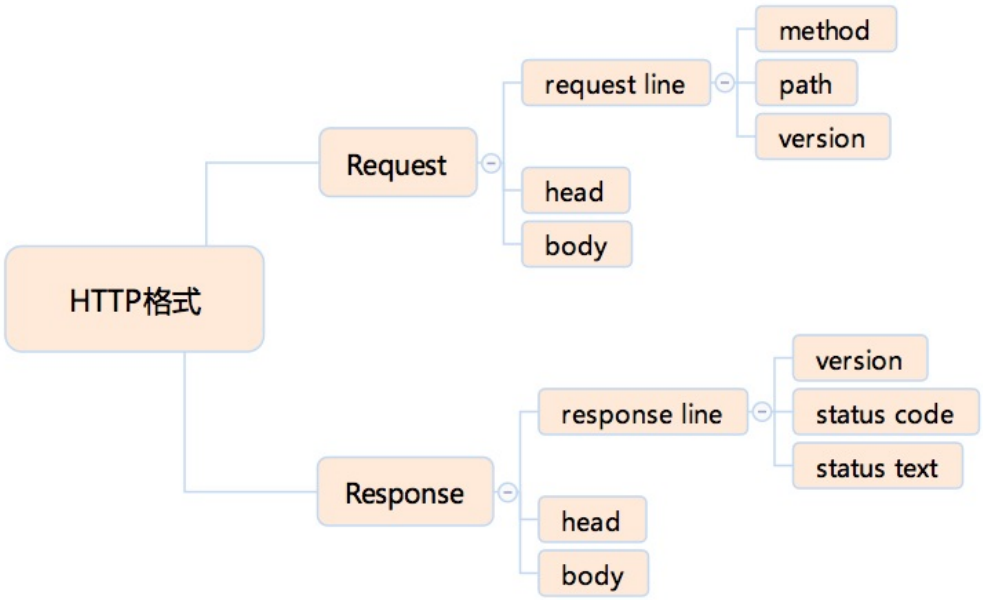


我们简单看一下，在这些部分中，path是请求的路径完全由服务端来定义，没有很多的特别内容；而version几乎都是固定字符串；response body是我们最熟悉的HTML，我在后面会有专门的课程介绍，这里也就不多讲了。

下面我们就来逐个给你介绍其它部分。

## HTTP Method（方法）

我们首先来介绍一下request line里面的方法部分。这里的方法跟我们编程中的方法意义类似，表示我们此次HTTP请求希望执行的操作类型。方法有以下几种定义：

- GET
- POST
- HEAD
- PUT
- DELETE
- CONNECT
- OPTIONS
- TRACE

浏览器通过地址栏访问页面都是GET方法。表单提交产生POST方法。

HEAD则是跟GET类似，只返回请求头，多数由JavaScript发起

PUT和DELETE分别表示添加资源和删除资源，但是实际上这只是语义上的一种约定，并没有强约束。

CONNECT现在多用于HTTPS和WebSocket。

OPTIONS和TRACE一般用于调试，多数线上服务都不支持。

### HTTP Status code（状态码）和 Status text（状态文本）

接下来我们看看response line的状态码和状态文本。常见的状态码有以下几种。

- 1xx：临时回应，表示客户端请继续。
- 2xx：请求成功。
  - 200：请求成功。
- 3xx: 表示请求的目标有变化，希望客户端进一步处理。
  - 301&302：永久性与临时性跳转。
  - 304：跟客户端缓存没有更新。
- 4xx：客户端请求错误。
  - 403：无权限。
  - 404：表示请求的页面不存在。
  - 418：It’s a teapot. 这是一个彩蛋，来自ietf的一个愚人节玩笑。（超文本咖啡壶控制协议）
- 5xx：服务端请求错误。
  - 500：服务端错误。
  - 503：服务端暂时性错误，可以一会再试。

对我们前端来说，1xx系列的状态码是非常陌生的，原因是1xx的状态被浏览器http库直接处理掉了，不会让上层应用知晓。

2xx系列的状态最熟悉的就是200，这通常是网页请求成功的标志，也是大家最喜欢的状态码。

3xx系列比较复杂，301和302两个状态表示当前资源已经被转移，只不过一个是永久性转移，一个是临时性转移。实际上301更接近于一种报错，提示客户端下次别来了。

304又是一个每个前端必知必会的状态，产生这个状态的前提是：客户端本地已经有缓存的版本，并且在Request中告诉了服务端，当服务端通过时间或者tag，发现没有更新的时候，就会返回一个不含body的304状态。

### HTTP Head (HTTP头)

HTTP头可以看作一个键值对。原则上，HTTP头也是一种数据，我们可以自由定义HTTP头和值。不过在HTTP规范中，规定了一些特殊的HTTP头，我们现在就来了解一下它们。

在HTTP标准中，有完整的请求/响应头规定，这里我们挑几个重点的说一下：

我们先来看看Request Header。

| Request Header | 规定 |
| --- | --- |
| Accept | 浏览器端接受的格式。 |
| Accept-Encoding: | 浏览器端接收的编码方式。 |
| Accept-Language | 浏览器端接受的语言，用于服务端判断多语言。 |
| Cache-Control | 控制缓存的时效性。 |
| Connection | 连接方式，如果是keep-alive，且服务端支持，则会复用连接。 |
| Host | HTTP访问使用的域名。 |
| If-Modified-Since | 上次访问时的更改时间，如果服务端认为此时间后自己没有更新，则会给出304响应。 |
| If-None-Match | 次访问时使用的E-Tag，通常是页面的信息摘要，这个比更改时间更准确一些。 |
| User-Agent | 客户端标识，因为一些历史原因，这是一笔糊涂账，多数浏览器的这个字段都十分复杂，区别十分微妙。 |
| Cookie | 客户端存储的cookie字符串。 |

接下来看一下Response Header。

| Response Header | 规定 |
| --- | --- |
| Cache-Control | 缓存控制，用于通知各级缓存保存的时间，例如max-age=0，表示不要缓存。 |
| Connection | 连接类型，Keep-Alive表示复用连接。 |
| Content-Encoding | 内容编码方式，通常是gzip。 |
| Content-Length | 内容的长度，有利于浏览器判断内容是否已经结束。 |
| Content-Type | 内容类型，所有请求网页的都是text/html。 |
| Date | 当前的服务器日期。 |
| ETag | 页面的信息摘要，用于判断是否需要重新到服务端取回页面。 |
| Expires | 过期时间，用于判断下次请求是否需要到服务端取回页面。 |
| Keep-Alive | 保持连接不断时需要的一些信息，如timeout=5, max=100。 |
| Last-Modified | 页面上次修改的时间。 |
| Server | 服务端软件的类型。 |
| Set-Cookie | 设置cookie，可以存在多个。 |
| Via | 服务端的请求链路，对一些调试场景至关重要的一个头。 |

这里仅仅列出了我认为比较常见的HTTP头，这些头是我认为前端工程师应该做到不需要查阅，看到就可以知道意思的HTTP头。完整的列表还是请你参考我给出的rfc2616标准。

## HTTP Request Body

HTTP请求的body主要用于提交表单场景。实际上，http请求的body是比较自由的，只要浏览器端发送的body服务端认可就可以了。一些常见的body格式是：

- application/json
- application/x-www-form-urlencoded
- multipart/form-data
- text/xml

我们使用html的form标签提交产生的html请求，默认会产生 application/x-www-form-urlencoded 的数据格式，当有文件上传时，则会使用multipart/form-data。

## HTTPS

在HTTP协议的基础上，HTTPS和HTTP2规定了更复杂的内容，但是它基本保持了HTTP的设计思想，即：使用上的Request-Response模式。

我们首先来了解下HTTPS。HTTPS有两个作用，一是确定请求的目标服务端身份，二是保证传输的数据不会被网络中间节点窃听或者篡改。

HTTPS的标准也是由RFC规定的，你可以查看它的详情链接：

https://tools.ietf.org/html/rfc2818

HTTPS是使用加密通道来传输HTTP的内容。但是HTTPS首先与服务端建立一条TLS加密通道。TLS构建于TCP协议之上，它实际上是对传输的内容做一次加密，所以从传输内容上看，HTTPS跟HTTP没有任何区别。

## HTTP 2

HTTP 2是HTTP 1.1的升级版本，你可以查看它的详情链接。

https://tools.ietf.org/html/rfc7540

HTTP 2.0 最大的改进有两点，一是支持服务端推送，二是支持TCP连接复用。

服务端推送能够在客户端发送第一个请求到服务端时，提前把一部分内容推送给客户端，放入缓存当中，这可以避免客户端请求顺序带来的并行度不高，从而导致的性能问题。

TCP连接复用，则使用同一个TCP连接来传输多个HTTP请求，避免了TCP连接建立时的三次握手开销，和初建TCP连接时传输窗口小的问题。

> Note: 其实很多优化涉及更下层的协议。IP层的分包情况，和物理层的建连时间是需要被考虑的。

## 结语

在这一节内容中，我们一起学习了浏览器的第一步工作，也就是“浏览器首先使用HTTP协议或HTTPS协议，向服务端请求页面”的这一过程。

在这个过程中，掌握HTTP协议是重中之重。我从一个小实验开始，带你体验了一次完整的HTTP请求过程。我们一起先分析了HTTP协议的结构。接下来，我分别介绍了HTTP方法、HTTP状态码和状态文本、HTTP Head和HTTP Request Body几个重点需要注意的部分。

最后，我还介绍了HTTPS和HTTP 2这两个补充版本，以便你可以更好地熟悉并理解新的特性。

你在工作中，是否已经开始使用HTTPS和HTTP 2协议了呢？用到了它们的哪些特性，请留言告诉我吧。

**精选留言：**

- Carson 2019-02-09 00:40:37
  现在工作中暂时只使用到 HTTPS。

  去年，看到一些公司已经开始着手更新 HTTP2，不少敬佩的前端高手做了分享。

  他们利用 HTTP2 服务端推送，以及 TCP 连接复用的特性，把 CSS 和 JS 文件分拆成更小的文件，分批下载。

  更小的文件意味着用户可以更快看到页面，以及性能的改善。与此同时，这种处理方式也对生产环境的工具链带来调整和改变。

  很有意思的变化。
  [56赞]

- yy不会笑 2019-02-09 23:06:12
  自己可以扩展补充以下
  > DNS查询得到IP

  > tcp/ip的并发限制

  > get和post的区别

  > 五层因特网协议栈

  > 长连接与短连接

  > http2.0与http1.1的显著不同点：

  > 强缓存与协商缓存 [26赞]

- 徐ઈu 2019-02-09 17:43:34
  老师真的很喜欢猫呐 [11赞]

- oillie 2019-02-09 23:35:07
  h2的头部会用哈夫曼编码压缩大小 [5赞]

- umaru 2019-02-09 02:38:07
  老师，浏览器渲染听说有重绘，回流什么的，哪里可以找到这一部分相关资料？ [5赞]

- hhk 2019-02-17 22:15:10
  那么 HTTP2 的 TCP 连接复用, 和 keep-alive 有什么区别呢?
  [4赞]

  作者回复2019-02-19 13:04:09
  嗯，这块我没细讲，其实就是HTTP2要加这个头才能复用连接。

- 新哥 2019-02-26 23:10:00
  option请求在线上也会存在吧？非简单请求中的预请求 [3赞]

- 一步 2019-02-23 11:23:00
  HTT2 还有一个很重要的特性：使用二进制代理文本进行传输，极大提高了传输的效率 [3赞]

  作者回复2019-03-01 15:26:09
  嗯 是 这块每太细讲 我觉得大家了解即可 主要是服务端的工作。

- 丫丫 2019-03-23 09:18:43
  软件有bug，听上一个音频后切换下一个音频时，下一个音频开始播放的时间不是从零开始，是上一个音频的暂停时间点开始 [2赞]

- 维维 2019-02-12 17:20:33
  找到了与老师的共同爱好，喜欢猫。 [2赞]

- 芳玥 2019-02-23 14:18:14
  3xx状态码，真的是给我补了一下。从来没踩过这个坑。 [1赞]

- ... 2019-02-17 13:51:52
  老师，网站做https升级后，由于TLS加密，第一次连接，速度慢一点是可以理解，但是之后的连接速度也变得挺慢的，这个用户体验不好，这个是不是跟我申请的https证书有很大关系，除此之外，有没有好的建议？ [1赞]

  作者回复2019-02-19 13:00:36
  怀疑是没有复用连接，这个凭你给的信息我没法判断，得具体拿log分析时间都花在哪里了，一般来说跟证书关系不大。

- 瞧，这个人 2019-02-16 08:02:32
  当5G来临，http小优化都不用找了 [1赞]

  作者回复2019-02-19 12:53:24
  这完全是一种误解，物理层优化没法解决上层协议的问题。

- Shaoyao·琚 2019-02-09 10:36:19
  棒！已经开始阅览 HTTP3 的文档了 [1赞]

- Russell 2019-04-11 11:25:08
  关于缓存，304这块我整理了一片文章。https://github.com/XiaodongTong/blog/blob/master/%E6%B5%8F%E8%A7%88%E5%99%A8/%E7%BC%93%E5%AD%98%E6%9C%BA%E5%88%B6.md

- 咸菜有点儿甜 2019-03-30 09:50:26
  Http1.1默认是开启keep-alive的，到http2意思是需要手动加入这个头么？

- 索 2019-03-26 17:17:27
  <!DOCTYPE html>
  <html>
  <head>
  <meta charset="UTF-8">
  <title></title>
  <style>
  /* var()函数 */
  :root {
  --bg-color: #cdcdcd;
  --font-color: blue;
  }
  body {
  background-color: var(--bg-color);
  }
  .title {
  color: var(--font-color);
  }
  /* attr()函数 */
  p:before {
  content: attr(data-foo) " ";
  }
  /* max()函数 */
  .test-max {
  height: 30px;
  background-color: #f00;
  width: max(30px, 50px);
  }
  /* toggle()函数 */
  ul {
  list-style-type:disk;
  }
  li > ul {
  list-style-type:toggle(disk, circle, square, box);
  }
  </style>
  </head>
  <body>
  <h1 class="title">标题引人注意</h1>

```
<p data-foo="hello">world</p>
<div class="test-max"></div>
<ul>
<li>1
<ul>
<li>1-1
<ul>
<li>1-1-1
<ul>
<li>1-1-1-1</li>
</ul>
</li>
</ul>
</li>
</ul>
</li>
</ul>
</body>
</html>
```

max(),min(),clamp() 浏览器基本都不支持

- 忠誠 2019-03-20 14:00:03
  Content-Type 几种常用的不同之处

- yeoman 2019-03-09 20:11:02
  那位提问tag是什么的同学应该是问304请求那块提到的tag，温大指的是协商缓存中的etag（entity tag

- umaru 2019-02-21 04:48:13
  服务器如何知道tag有没有更新？
  是有某个地方可以设置还是我需要刻意去修改页面中某个标签？

  作者回复2019-03-01 15:02:41
  一般tag是页面的信息摘要，你的服务器受到端上的tag，会那这个tag跟页面的信息摘要比对，如果相同就直接回复304无需更新了，如果不同就回复页面的内容。